Sistema financeiro LLM

Custos, uso e otimização dos modelos de linguagem do DonaSystem. Referência operacional para decisões de budget e configuração.

DONASYSTEM | MARÇO 2026 | CONFIDENCIAL

LLM

TABELA DE PREÇOS

Modelos *disponíveis*

01

Provider: Anthropic (Claude). Preços por 1 milhão de tokens. Março 2026.

MODELO	INPUT / 1M	OUTPUT / 1M	PERFIL DE USO	STATUS
Claude 3 Haiku	US$ 0,25	US$ 1,25	Legado	DESCONTINUADO
Claude 4.5 Haiku	US$ 1,00	US$ 5,00	Crons, checagens, tarefas rotineiras	ATIVO
Claude 3.5 Sonnet	US$ 3,00	US$ 15,00	Produção intermediária	DISPONÍVEL
Claude 4.6 Sonnet	US$ 3,00	US$ 15,00	Conteúdo, análise, código	ATIVO
Claude 3 Opus (legado)	US$ 15,00	US$ 75,00	5x mais caro que atual	DESCONTINUADO
Claude 4.6 Opus	US$ 5,00	US$ 25,00	Raciocínio complexo, estratégia	PADRÃO

ECONOMIA COM CACHE

Prompt caching

Tokens repetidos (system prompt, AGENTS.md, SOUL.md) são cacheados automaticamente. Economia de 90% no input.

MODELO	INPUT NORMAL	INPUT CACHEADO	ECONOMIA
Haiku 4.5	US$ 1,00/M	US$ 0,10/M	90%
Sonnet 4.6	US$ 3,00/M	US$ 0,30/M	90%
Opus 4.6	US$ 5,00/M	US$ 0,50/M	90%

CACHE HIT RATE ATUAL

16% dos tokens de entrada estão sendo cacheados. Há espaço para otimizar prompts de sistema e aumentar essa taxa.

SETUP ATUAL

Nossa configuração

02

Modelo padrão: Claude Opus 4.6. Usado em todas as conversas e crons que não especificam modelo.

Opus 4.6	9	10	3
MODELO PADRÃO	CRONS ATIVOS	AGENTES (TÓPICOS)	PERFIS DE AUTH

PERFIS DE AUTENTICAÇÃO

PERFIL	PROVIDER	TIPO	PRIORIDADE
anthropic:manual	Anthropic	Token	1 (primário)
anthropic:default	Anthropic	API Key	2
anthropic:donabot	Anthropic	Token	3 (fallback)

USO POR AGENTE

Tópicos do Equipe

AGENTE	TÓPICO	MODELO	TIPO DE TAREFA
Dona	2	Opus 4.6	Coordenação, estratégia, decisões
Eva	5	Opus 4.6	Arquitetura de agentes
Aurora	6	Opus 4.6	Design, HTML/CSS, PDFs
Harpia	7	Opus 4.6	Roteiros, vídeo
Masterson	8	Opus 4.6	Copy, escrita longa
Vega	10	Opus 4.6	Social media, pesquisa
Orion	11	Opus 4.6	Código, automações
Helios	12	Opus 4.6	Tráfego, Meta Ads
Nexa	14	Opus 4.6	Imagens, curadoria visual
Atlas	15	Opus 4.6	Orquestração, planejamento

AUTOMAÇÕES

Crons ativos

03

9 crons automatizados. 4 já usam Haiku (econômico). 5 ainda rodam no Opus sem necessidade.

CRON	MODELO	FREQUÊNCIA	EXEC/MÊS	CUSTO
health-monitor	Opus 4.6	A cada 1h	720	**~US$ 63**
checagem-proativa-6h	Haiku 4.5	4x/dia	120	~US$ 2,10
organizacao-memoria	Haiku 4.5	1x/dia	30	~US$ 0,90
backup-diario	Opus 4.6	1x/dia	30	~US$ 1,88
watchdog-monitor	Haiku 4.5	1x/dia	30	~US$ 0,60
stats-collector	Opus 4.6	1x/dia	30	~US$ 3,75
task-reminder	Opus 4.6	1x/dia	30	~US$ 3,00
security-audit	Haiku 4.5	1x/semana	4	~US$ 0,08
consolidacao-semanal	Opus 4.6	1x/semana	4	~US$ 0,90
Total crons			998	~US$ 76/mês

VISUALIZAÇÃO DE CUSTOS POR CRON

O health-monitor sozinho consome 83% do custo de crons. Migrar para Haiku economiza ~US$ 61/mês imediatamente.

✦ RECOMENDAÇÃO PRIORITÁRIA

ESTIMATIVA MENSAL

Custo total estimado

04

Premissas: ~50 conversas/dia, contexto médio ~50k tokens, output médio ~2k tokens, cache hit 16%.

US$ 76
CRONS (FIXO)

US$ 200-400
CONVERSAS + SUBAGENTES (VARIÁVEL)

US$ 276-476
TOTAL ESTIMADO/MÊS

CENÁRIOS DE OTIMIZAÇÃO

Comparativo de custos

CENÁRIO	CONFIGURAÇÃO	CUSTO/MÊS	ECONOMIA
A (atual)	Tudo no Opus + 4 crons Haiku	US$ 350-500	Baseline
B (recomendado)	Opus para Isis + Sonnet para produção + Haiku para crons	US$ 150-250	~50%
C	Sonnet como padrão + Opus só para estratégia	US$ 100-180	~65%
D	Haiku para tudo (mínimo viável)	US$ 30-60	~85%

AÇÃO IMEDIATA (5 MIN)

Migrar 5 crons

Health-monitor, backup, stats-collector, task-reminder e consolidacao para Haiku/Sonnet. Economia: ~US$ 67/mês sem perda de qualidade.

AÇÃO MÉDIA (REQUER TESTE)

Sonnet para execução

Usar Sonnet como padrão para Orion, Nexa e Vega. Manter Opus para Dona, Atlas, Masterson e Aurora. Economia adicional: ~US$ 40-80/mês.

PERFIL DE CADA MODELO

ECONÔMICO

Haiku 4.5

Latência: 1-3s. Bom para checagens, classificação, tarefas com instrução clara. 5x mais barato que Opus.

EQUILIBRADO

Sonnet 4.6

Latência: 3-8s. Bom para conteúdo, código moderado, análise. 60% mais barato que Opus.

PREMIUM

Opus 4.6

Latência: 5-15s. O melhor em raciocínio complexo, estratégia, copy avançada. O mais caro.

REGRA DE OURO

Quando usar *cada modelo*

05

DECISÃO RÁPIDA

Tarefa rotineira, checagem ou formatação → Haiku
Produção de conteúdo ou código moderado → Sonnet
Estratégia, decisão complexa ou copy de alto impacto → Opus
Não tem certeza → Sonnet (melhor custo-benefício)

TAREFA	MODELO IDEAL	JUSTIFICATIVA
Heartbeat, health check	HAIKU	Instrução simples, resposta binária
Backup, organização de memória	HAIKU	Comandos de sistema, sem raciocínio
Watchdog, auditoria	HAIKU	Verificação de lista, pouca criatividade
Posts, legendas, pesquisa	SONNET	Conteúdo bom, não precisa de Opus
Código, scripts, automações	SONNET	Qualidade suficiente para a maioria
Geração de imagens (prompts)	SONNET	Prompts não exigem raciocínio profundo
Copy de vendas, ebooks	OPUS	Persuasão requer raciocínio avançado
Estratégia, decisões de negócio	OPUS	Múltiplas variáveis, consequências reais
Orquestração de cadeias	OPUS	Coordenação multi-agente é complexa
Design system, HTML avançado	OPUS	CSS/JS complexo precisa de precisão

CUSTOS COMPLEMENTARES

Outras *APIs*

SERVIÇO	CUSTO	USO
OpenAI Whisper API	~US$ 0,006/min	Transcrição de áudio (sob demanda)
Google Gemini (search)	Free tier	Buscas web via OpenClaw
RapidAPI (Instagram, YT...)	Freemium	Scraping e APIs diversas
ElevenLabs TTS	Variável	Text-to-speech (sob demanda)
Meta Ads API	Gratuito	Dados de campanhas
Nano Banana Pro (Gemini)	Via Gemini key	Geração de imagens

MONITORAMENTO

DASHBOARD

console.anthropic.com/settings/billing

SESSÃO ATUAL

Comando /status mostra tokens e cache hit

LOGS

Gateway registra tokens por request